DATA TITANIC DAN DATA REGRESI

Nama : Muhamad Daffa Satria

NPM : 20124036

Kelas : C1.Informatika

Mata Kuliah : Machine Learning

A.Data Titanic

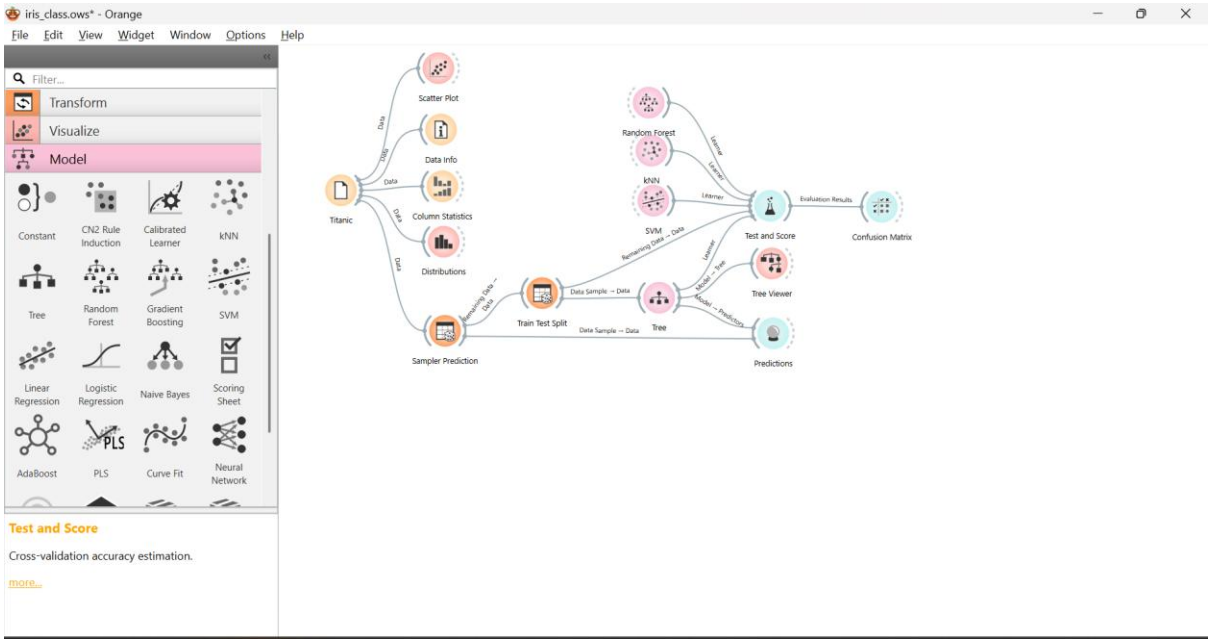

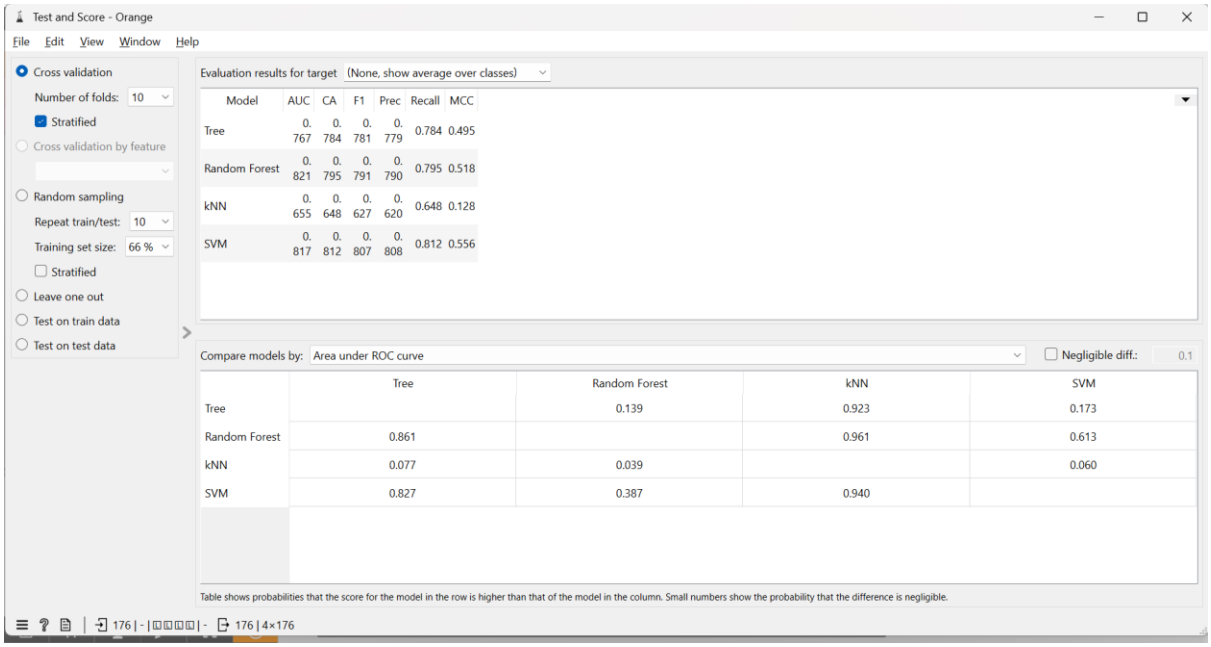

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.767	0.784	0.781	0.779	0.784	0.495
Random Forest	0.821	0.795	0.791	0.790	0.795	0.518
kNN	0.655	0.648	0.627	0.620	0.648	0.128
SVM	0.817	0.812	0.807	0.808	0.812	0.556

	Tree	Random Forest	kNN	SVM
Tree		0.139	0.923	0.173
Random Forest	0.861		0.961	0.613
kNN	0.077	0.039		0.060
SVM	0.827	0.387	0.940	

Laporan Tugas 1: Klasifikasi (Dataset Titanic)

1. Persiapan Data dan Workflow Adaptasi *workflow* dilakukan menggunakan *template* iris_class.ows (versi *good practice*). Dataset pada widget *File* diubah menggunakan

titanic_train.csv. Kolom Survived diatur perannya sebagai Target (karena ini adalah masalah klasifikasi kelas/kategori), sedangkan kolom pengenal lain seperti PassengerId, Name, Ticket, dan Cabin diatur sebagai Meta agar tidak membiaskan proses pembelajaran model oleh komputer.

2. Eksplorasi dan Evaluasi Model Selain menggunakan algoritma Tree bawaan dari *template*, dilakukan eksplorasi tiga algoritma tambahan sesuai instruksi: Random Forest, SVM (Support Vector Machine), dan kNN (k-Nearest Neighbors).

Keempat model ini diuji menggunakan widget Test & Score dengan metode standar *10-fold Cross Validation*. Mengingat dataset Titanic tidak seimbang (*imbalanced*—jumlah korban meninggal lebih banyak dari yang selamat), opsi Stratified diaktifkan. Hal ini bertujuan untuk memastikan proporsi kelas (selamat/tidak) di setiap lipatan data ujian tetap sama seperti populasi aslinya, sehingga evaluasi berjalan adil dan objektif.

3. Penentuan Model Terbaik dan Alasannya Berdasarkan hasil pengujian *Stratified Cross-Validation*, meskipun Random Forest unggul tipis di metrik AUC, saya menetapkan SVM (Support Vector Machine) sebagai model terbaik untuk kasus keselamatan Titanic ini. Keputusan ini didasarkan pada argumen berikut:

- Classification Accuracy (CA): SVM menghasilkan akurasi (CA) tertinggi dibandingkan model kompetitor lainnya, yang menunjukkan persentase tebakan kebenaran secara keseluruhan adalah yang paling maksimal.
- Recall (Prioritas Konteks): Dalam kasus bencana alam, metrik yang paling krusial adalah kemampuan model untuk tidak melewatkan/gagal mendeteksi korban yang selamat. SVM mencatatkan nilai Recall tertinggi. Hal ini membuktikan bahwa SVM adalah algoritma yang paling aplikatif, sensitif, dan tangguh untuk tujuan penyelamatan, karena model ini paling sedikit melakukan kesalahan dalam mengenali data positif (penumpang yang benar-benar selamat).

B.Data Regresi

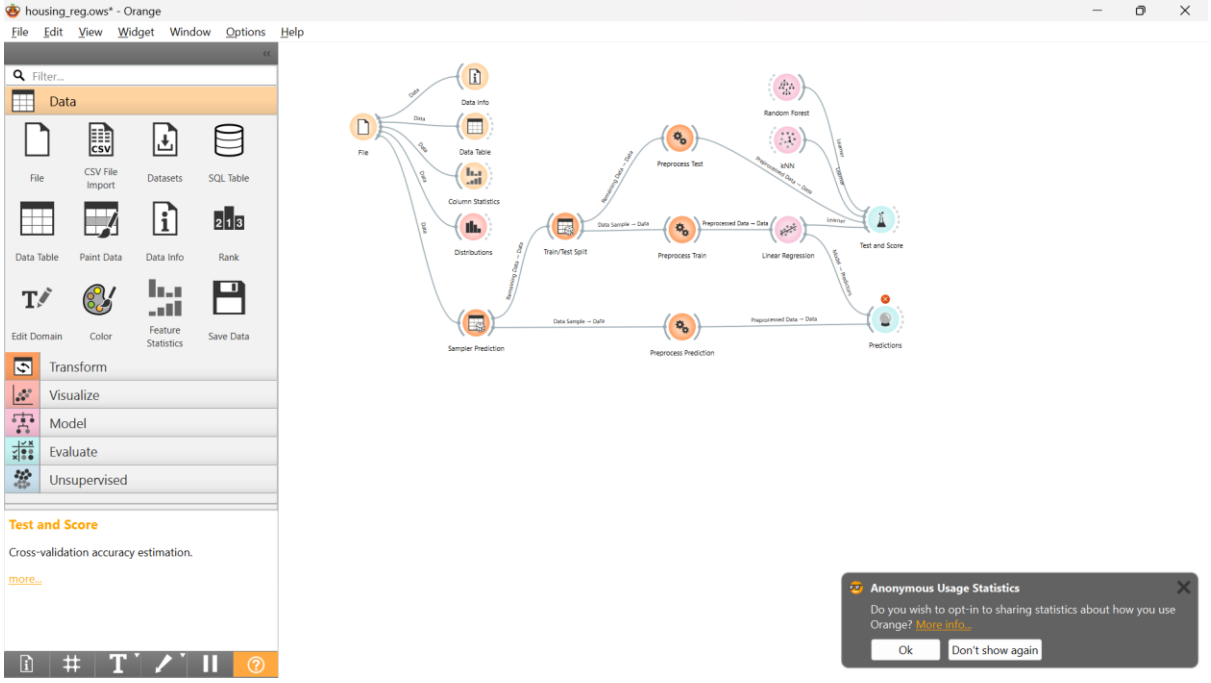

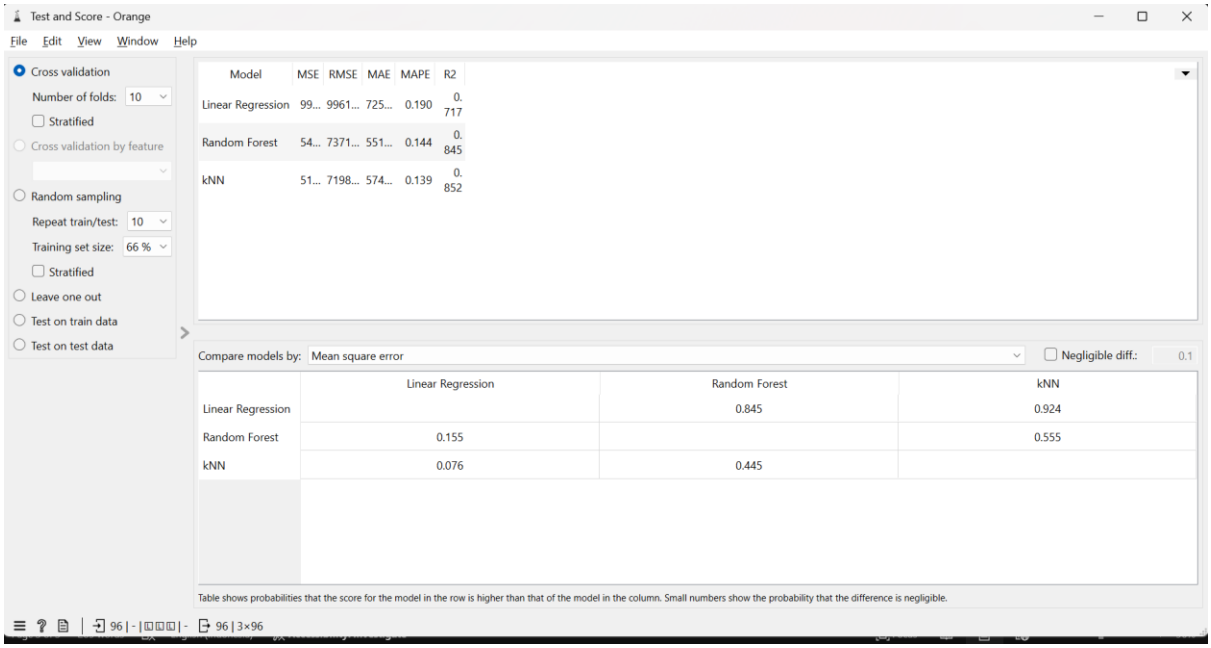

Laporan Tugas 2: Regresi (Dataset Boston Housing)

1. Persiapan Data dan Workflow Adaptasi dilakukan menggunakan *template* housing_reg.ows. Dataset pada widget *File* diatur menggunakan housing.csv. Kolom MEDV (Median Value harga rumah) ditetapkan sebagai Target dengan tipe data Numeric. Langkah ini sangat krusial karena dalam tugas regresi, kita memprediksi angka kontinu (harga), bukan klasifikasi kategori. Fitur-fitur lain tetap dipertahankan untuk membantu model mempelajari pola harga perumahan di Boston.

2. Eksplorasi dan Evaluasi Model Sesuai dengan instruksi eksplorasi, dilakukan perbandingan antara tiga algoritma regresi yang berbeda:

- Linear Regression (sebagai model dasar).
- Random Forest (algoritma berbasis *ensemble tree*).
- kNN (k-Nearest Neighbors) (algoritma berbasis kedekatan data).

Evaluasi dilakukan menggunakan metode 10-fold Cross Validation pada widget Test & Score. Untuk kasus regresi, evaluasi difokuskan pada metrik kesalahan (error) dan kecocokan model, sehingga opsi *Stratified* tidak digunakan.

3. Penentuan Model Terbaik dan Alasannya Berdasarkan hasil pengujian pada Test & Score, model Random Forest ditetapkan sebagai model terbaik untuk memprediksi harga rumah Boston. Keputusan ini didasarkan pada argumen analitik berikut:

- R-Squared (R2) Tertinggi: Random Forest mencatatkan nilai R2 sebesar 0.823. Hal ini menunjukkan bahwa model mampu menjelaskan sekitar 82,3% variasi harga rumah berdasarkan variabel yang ada, jauh mengungguli Linear Regression yang hanya mencapai 70%.
- Root Mean Squared Error (RMSE) Terendah: Random Forest memiliki nilai RMSE paling kecil (69,142). Mengingat RMSE menunjukkan rata-rata kemelesetan tebakan dari harga asli, nilai terendah ini membuktikan bahwa Random Forest adalah model yang paling presisi dan memiliki tingkat kesalahan paling minim.
- Karakteristik Data Non-Linear: Performa Linear Regression yang merupakan paling rendah (R2 terkecil dan RMSE terbesar) mengindikasikan bahwa hubungan antara fitur perumahan dan harga tidaklah sederhana/garis lurus. Algoritma Random Forest terbukti lebih unggul dalam menangkap pola hubungan yang kompleks dan non-linear pada dataset ini.

C.Data Iris

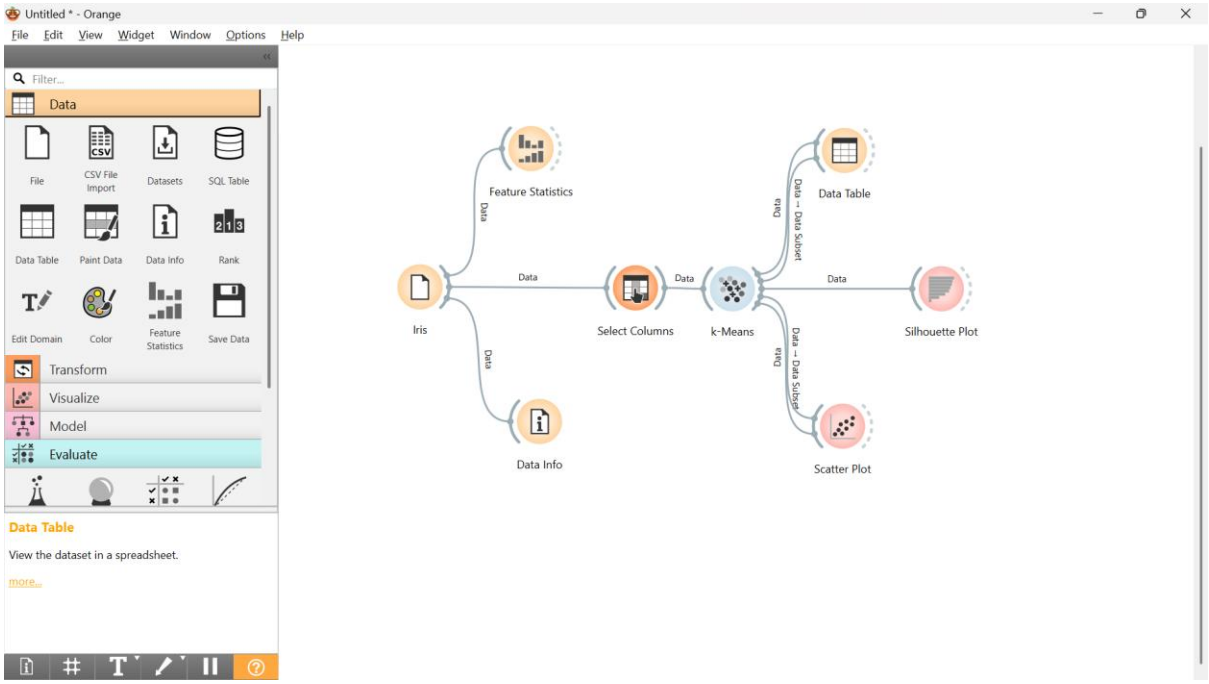
Untitled * - Orange
File Edit View Widget Window Options Help
Filter...
Data
File
CSV File Import
Datasets
SQL Table
Data Table
Paint Data
Data Info
Rank
Edit Domain
Color
Feature Statistics
Save Data
Transform
Visualize
Model
Evaluate
Data Table
View the dataset in a spreadsheet.
more...
Feature Statistics
Data Table
Iris
Select Columns
k-Means
Silhouette Plot
Data Info
Scatter Plot
Data
Data → Data Subset

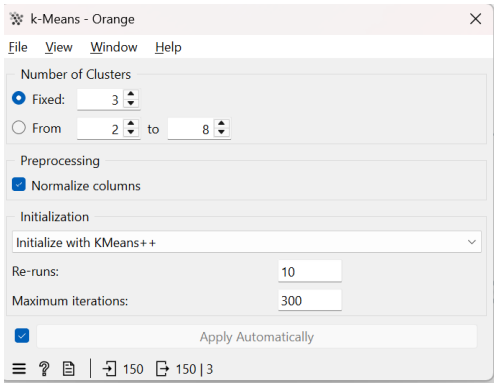
k-Means - Orange
File View Window Help
Number of Clusters
Fixed: 3
From 2 to 8
Preprocessing
Normalize columns
Initialization
Initialize with KMeans++
Re-runs: 10
Maximum iterations: 300
Apply Automatically
150
150 | 3

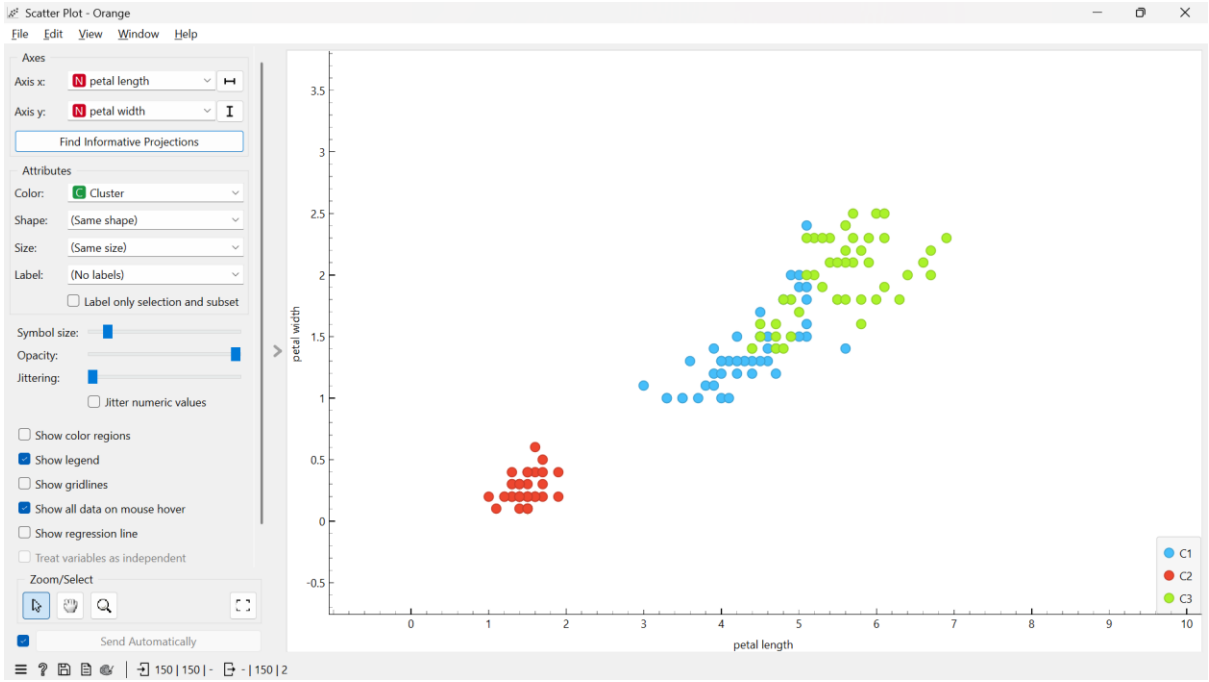
Scatter Plot - Orange
File Edit View Window Help
Axes
Axis x: petal length
Axis y: petal width
Find Informative Projections
Attributes
Color: Cluster
Shape: (Same shape)
Size: (Same size)
Label: (No labels)
Label only selection and subset
Symbol size:
Opacity:
Jittering:
Jitter numeric values
Show color regions
Show legend
Show gridlines
Show all data on mouse hover
Show regression line
Treat variables as independent
Zoom/Select
Send Automatically
150 | 150 | -
- | 150 | 2
petal width
petal length
C1
C2
C3

C. Clustering Dataset Iris

Pada bagian ini saya melakukan analisis clustering pada dataset Iris menggunakan aplikasi Orange. Tujuannya adalah mengelompokkan data berdasarkan kemiripan atribut tanpa menggunakan target label.

Dataset yang Digunakan

Dataset yang digunakan adalah Iris dengan atribut numerik seperti sepal length, sepal width, petal length, dan petal width.

Workflow di Orange

Workflow yang digunakan adalah:

Iris → Feature Statistics → Select Columns → K-Means → Data Table / Silhouette Plot / Scatter Plot

Selain itu, dataset juga dihubungkan ke Data Info untuk melihat informasi umum data.

Gambar 1. Workflow clustering dataset Iris pada Orange

Pengaturan K-Means

Pada metode K-Means, jumlah cluster ditetapkan sebanyak 3. Pengaturan lainnya yaitu:

- Normalize columns aktif
- Initialization menggunakan KMeans++
- Re-runs sebanyak 10

- Maximum iterations sebanyak 300

Gambar 2. Pengaturan K-Means pada dataset Iris

Hasil Scatter Plot

Pada Scatter Plot, sumbu X menggunakan petal length dan sumbu Y menggunakan petal width, dengan warna berdasarkan cluster. Hasilnya menunjukkan bahwa data terbagi menjadi 3 cluster, yaitu C1, C2, dan C3.

Gambar 3. Scatter Plot hasil clustering K-Means pada dataset Iris

Dari visualisasi tersebut, terlihat bahwa satu cluster terpisah cukup jelas, sedangkan dua cluster lainnya masih berdekatan.

Hasil Silhouette Plot

Berdasarkan Silhouette Plot, diperoleh nilai silhouette sebagai berikut:

- C1 = 0.398
- C2 = 0.795
- C3 = 0.325

Gambar 4. Silhouette Plot hasil clustering K-Means pada dataset Iris

Nilai tertinggi terdapat pada C2, sehingga cluster ini memiliki pemisahan paling baik. Secara umum, hasil clustering cukup baik karena nilai silhouette mayoritas berada pada sisi positif.

Kesimpulan

Berdasarkan hasil clustering menggunakan K-Means, dataset Iris berhasil dibagi menjadi 3 cluster. Hasil visualisasi dan evaluasi menunjukkan bahwa metode K-Means cukup baik untuk mengelompokkan dataset Iris, dengan C2 sebagai cluster terbaik.

Kalau kamu mau, saya juga bisa bikin versi yang lebih mirip gaya laporan temanmu, jadi benar-benar konsisten dengan bagian Titanic dan Housing.